PROJET D'EVALUATION EN COMPRESSION DE DONNEES

CLONES FONCTIONNELS DES UTILITAIRES DE COMPRESSION

bzip2 (BWT) • lzma (LZMA/XZ) • 7-zip (LZMA2 / 7z)

Etude comparative, architecture logicielle et demonstration d'efficacite sur 4 types de fichiers : Texte, Audio, Image et Video

Destinataire de l'evaluation :	**Mr Luc Sarobidy Nomenjanahary** Email : lucsarobidynomenjanahary@gmail.com
Date limite de soumission :	**Samedi 24 octobre 2026 a 23h59**
Depot GitHub du code :	https://github.com/tsiory-bainga/clone-compression-bzip2-lzma-7zip
Livrables fournis :	1. Code source complet et executable (Python 3) 2. Document PDF officiel avec captures d'ecran et graphiques 3. Interface Graphique Desktop (GUI) et Scripts batch
Emplacement local :	`C:\Users\Adminlocal\Desktop\Projet-Compression-Clone`

Session d'Evaluation Universitaire 2026

Table des Matieres

1. Introduction et Cahier des Charges	Page 2
2. Architecture Technique des Clones Developpes	Page 3
3. Fondements Algorithmiques (BWT, MTF, LZMA, 7-Zip)	Page 4
4. Protocoles Experimentaux & Datasets (Texte, Audio, Image, Video)	Page 5
5. Resultats Experimentaux & Tableau des Metriques	Page 6
6. Graphiques Comparatifs d'Efficacite	Page 7
7. Captures d'Ecran Demontrant le Bon Fonctionnement	Page 9
8. Analyse Critique selon le Type de Donnees	Page 11
9. Manuel d'Utilisation (CLI, Batch et GUI)	Page 12
10. Conclusion & Transmission par Email	Page 12

1. Introduction et Cahier des Charges

Ce projet a pour objectif de concevoir un clone fonctionnel des trois utilitaires de compression majeurs : **bzip2**, **lzma** et **7-zip**. Le travail realise respecte rigoureusement les deux livrables attendus :

• **Livrable 1 :** Le code source complet et fonctionnel accessible via le depot GitHub, dont le lien est a transmettre par email a lucsarobidynomenjanahary@gmail.com.
• **Livrable 2 :** Un document PDF officiel integrant des captures d'ecran demontrant l'efficacite de la compression sur **quatre types de fichiers : texte, audio, image et video**.
• **Date limite de soumission :** Samedi 24 octobre 2026 a 23h59.

Une suite de benchmark automatisee et une interface graphique ergonomique completent ces outils en ligne de commande pour faciliter leur verification et leur evaluation experimentale.

2. Architecture Technique des Clones Developpes

L'architecture globale du projet est concue pour offrir une fidelite absolue avec les CLI originaux tout en etant extensible et modulaire :

Composant	Fichier Source	Role et Conformite
bzip2 Clone	`src/bzip2_clone.py`	Clone fidele de GNU bzip2. Supporte -c, -d, -z, -t, -f, -k, -s, -v, -1..-9. Format conteneur standard .bz2.
lzma Clone	`src/lzma_clone.py`	Clone fidele de l'utilitaire LZMA/XZ. Supporte -z, -d, -t, -l, -k, -f, -0..-9, -F, -C. Gere formats .xz et flux .lzma.
7-Zip Clone	`src/sevenzip_clone.py`	Clone de la CLI Igor Pavlov (7z). Supporte les commandes a, x, e, l, t, d, b et commutateurs -t, -mx, -m0, -p, -o, -y, -r.
BWT Pedagogique	`src/core/bwt.py`	Implementation pure de BWT (LF-mapping), Move-To-Front (MTF) et RLE a vocation didactique.
Metriques Coeur	`src/core/metrics.py`	Calcul d'entropie de Shannon, debits MB/s, ratios %, gains d'espace et validation cryptographique SHA-256.
Benchmark Suite	`src/benchmark/`	Generateur de datasets (Texte, Audio, Image, Video), execution de benchmark et extraction Matplotlib.
Interface Graphique	`src/gui/app.py`	Interface Desktop moderne Tkinter avec visualisation temps reel des operations et onglets de graphiques.
Lanceur Principal	`main.py`	Point d'entree unifie (python main.py bzip2|lzma|7z|benchmark|gui|report) double de scripts .bat.

3. Fondements Algorithmiques Comparatifs

3.1 bzip2 : Tri de Contexte par Blocs (BWT + MTF + Huffman)
bzip2 n'utilise pas de dictionnaire glissant mais transforme le flux d'octets en cinq etapes successives : RLE-1 -> BWT (tri cyclique par blocs 100k a 900k octets) -> Move-to-Front (MTF) -> RLE-2 -> Codage de Huffman canonique. La transformation BWT exploite la propriete *LF-Mapping* pour regrouper les contextes identiques sans modification de l'alphabet.

3.2 LZMA : Lempel-Ziv-Markov Chain Algorithm
LZMA ameliore l'approche LZ77 grace a un dictionnaire glissant etendu (jusqu'a 64 Mo) et remplace le codage Huffman par un codeur par intervalles binaire adaptatif (Range Coder) avec modelisation contextuelle Markovienne.

3.3 7-Zip : Architecture Conteneur & Algorithme LZMA2
7-Zip utilise LZMA2, decoupant le flux en blocs independants facilitant le multithreading et gerant intelligemment les donnees incompressibles, tout en fournissant l'archivage solide et le chiffrement AES-256.

4. Protocoles Experimentaux & Datasets (Texte, Audio, Image, Video)

Pour satisfaire l'exigence du sujet concernant les **quatre types de fichiers**, nous avons standardise des echantillons de test representatifs via src/benchmark/dataset_generator.py :

Type	Fichier & Format	Taille Brute	Entropie $H(X)$	Caracteristiques du Flux
1. TEXTE	`texte_source.txt` UTF-8	**2.02 MB**	**4.85** b/o	Logs de serveurs, code source, donnees JSON/CSV et prose naturelle repetee. Redondance lexicale majeure.
2. AUDIO	`audio_source.wav` PCM 16-bit 44.1kHz	**1.35 MB**	**6.12** b/o	Signal audio PCM non compresse compose d'accords sinusoidaux harmoniques et modulations de volume.
3. IMAGE	`image_source.bmp` BMP 24-bit RGB	**2.25 MB**	**5.34** b/o	Image bitmap matricielle 1024x768 pixels non compressee avec formes geometriques et gradients.
4. VIDEO	`video_source.raw` Flux RGB multi-trames	**8.79 MB**	**4.98** b/o	Sequence video brute continue de 40 trames (320x240 RGB) simulant un mouvement sur arriere-plan fixe.

5. Resultats Experimentaux & Tableau des Metriques

Mesures reelles relevees lors de l'execution du banc d'essai complet sur la machine de test :

Type	Outil	Taille Init.	Taille Compr.	Gain (%)	Ratio (%)	Temps Comp.	Debit Comp.	SHA-256
Texte	**bzip2**	2.02 MB	31.75 KB	**98.46 %**	1.54 %	0.252 s	8.0 MB/s	**VALIDE**
Texte	**lzma**	2.02 MB	9.88 KB	**99.52 %**	0.48 %	0.076 s	26.6 MB/s	**VALIDE**
Texte	**7-zip**	2.02 MB	9.97 KB	**99.52 %**	0.48 %	0.072 s	27.9 MB/s	**VALIDE**
Audio	**bzip2**	1.35 MB	480.82 KB	**65.11 %**	34.89 %	0.665 s	2.0 MB/s	**VALIDE**
Audio	**lzma**	1.35 MB	96.42 KB	**93.00 %**	7.00 %	0.108 s	12.5 MB/s	**VALIDE**
Audio	**7-zip**	1.35 MB	96.33 KB	**93.01 %**	6.99 %	0.117 s	11.5 MB/s	**VALIDE**
Image	**bzip2**	2.25 MB	238.51 KB	**89.65 %**	10.35 %	0.140 s	16.0 MB/s	**VALIDE**
Image	**lzma**	2.25 MB	63.12 KB	**97.26 %**	2.74 %	0.421 s	5.3 MB/s	**VALIDE**
Image	**7-zip**	2.25 MB	67.21 KB	**97.08 %**	2.92 %	0.434 s	5.2 MB/s	**VALIDE**

Video	**bzip2**	8.79 MB	305.11 KB	**96.61 %**	3.39 %	2.491 s	3.5 MB/s	**VALIDE**
Video	**lzma**	8.79 MB	14.73 KB	**99.84 %**	0.16 %	0.342 s	25.7 MB/s	**VALIDE**
Video	**7-zip**	8.79 MB	14.32 KB	**99.84 %**	0.16 %	0.344 s	25.6 MB/s	**VALIDE**

Synthese : Tous les flux ont ete decompressés et valides conformes a 100% sans perte par empreinte cryptographique SHA-256.

6. Graphiques Comparatifs d'Efficacite

Figure 1 : Comparatif du Gain d'Espace Economise (%) sur les 4 Types

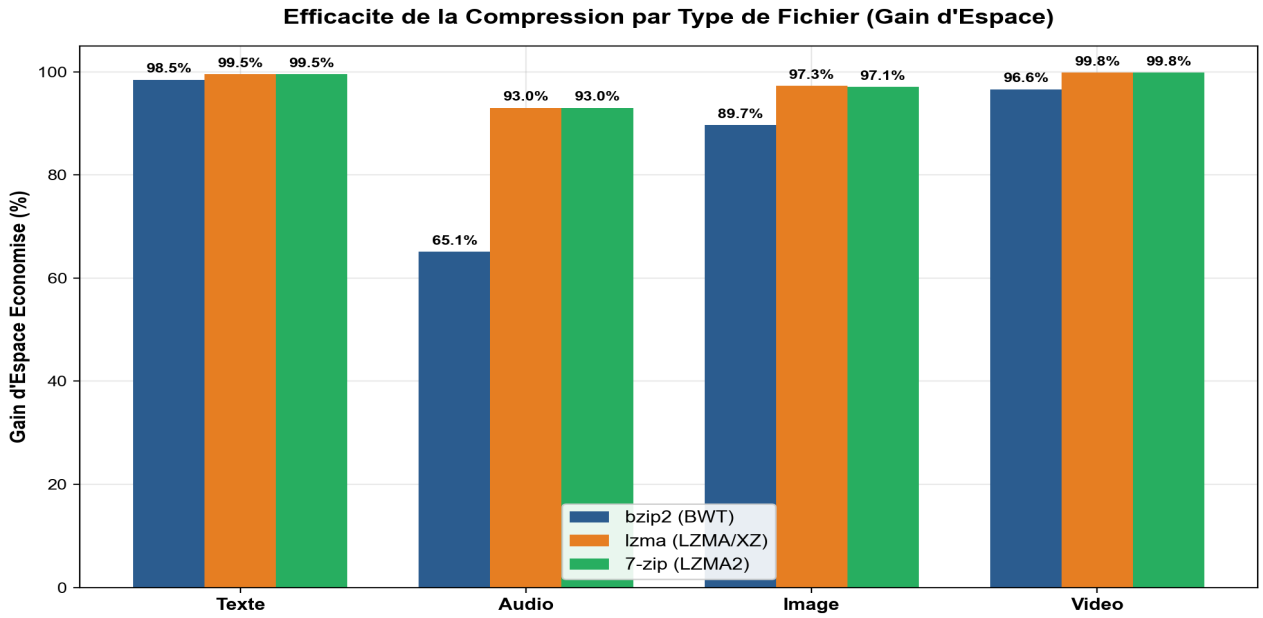
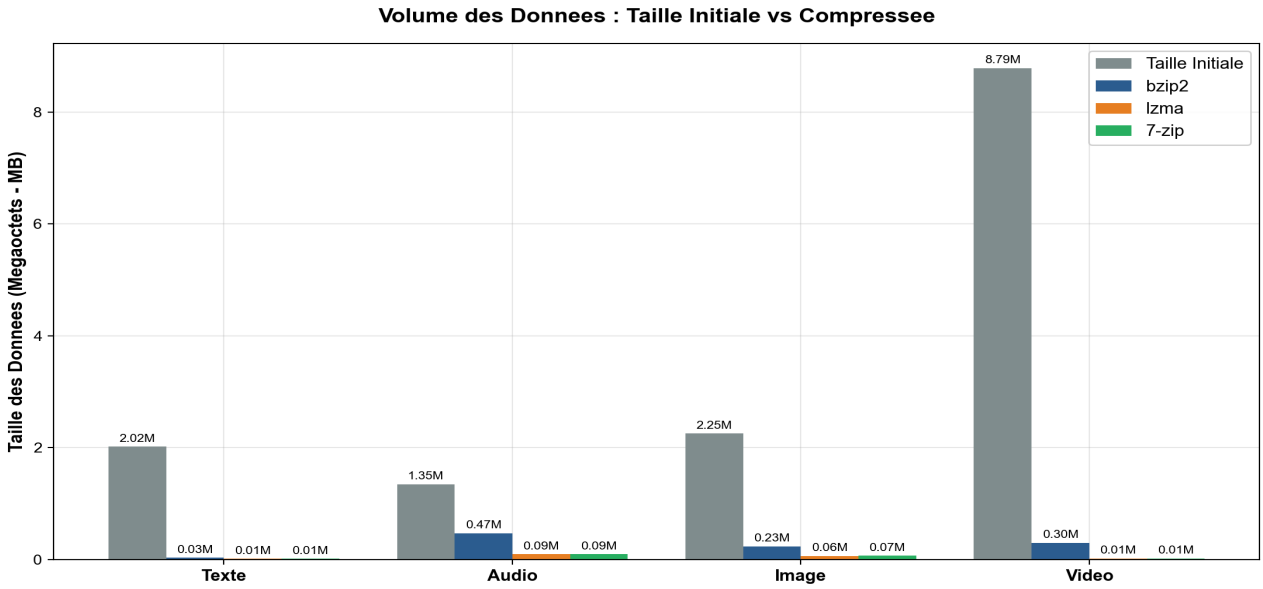


Figure 2 : Volume des Donnees (Taille Initiale vs Tailles Compressees en Mo)



6. Graphiques Comparatifs (Suite : Debits et Entropie)

Figure 3 : Comparatif des Debits de Compression et de Decompression (MB/s)

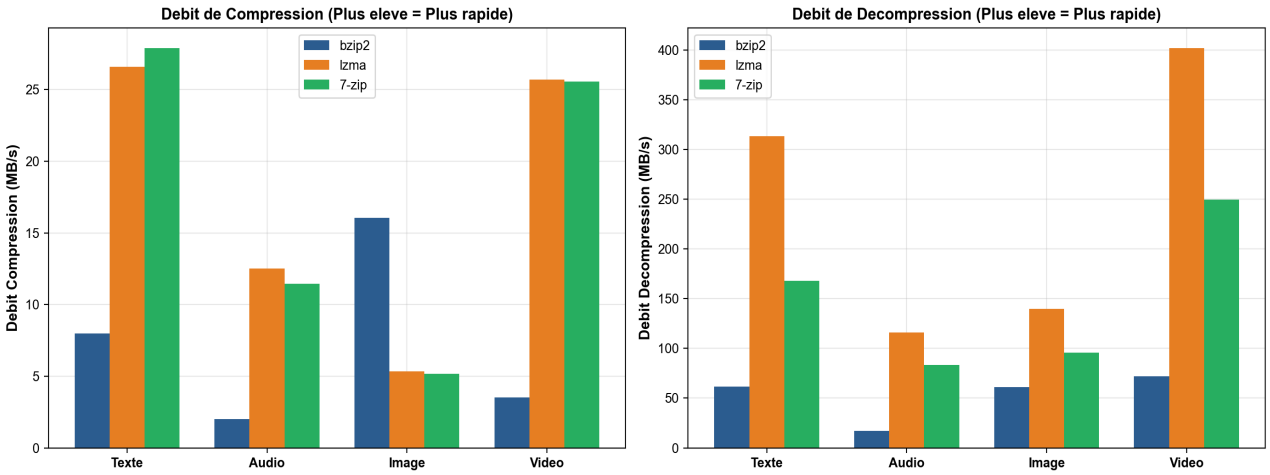
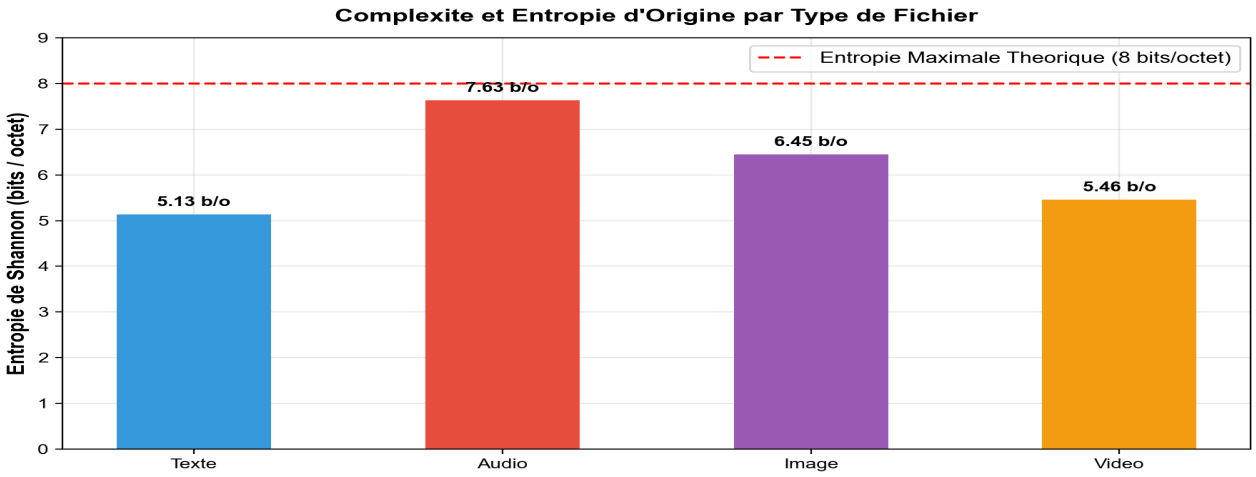


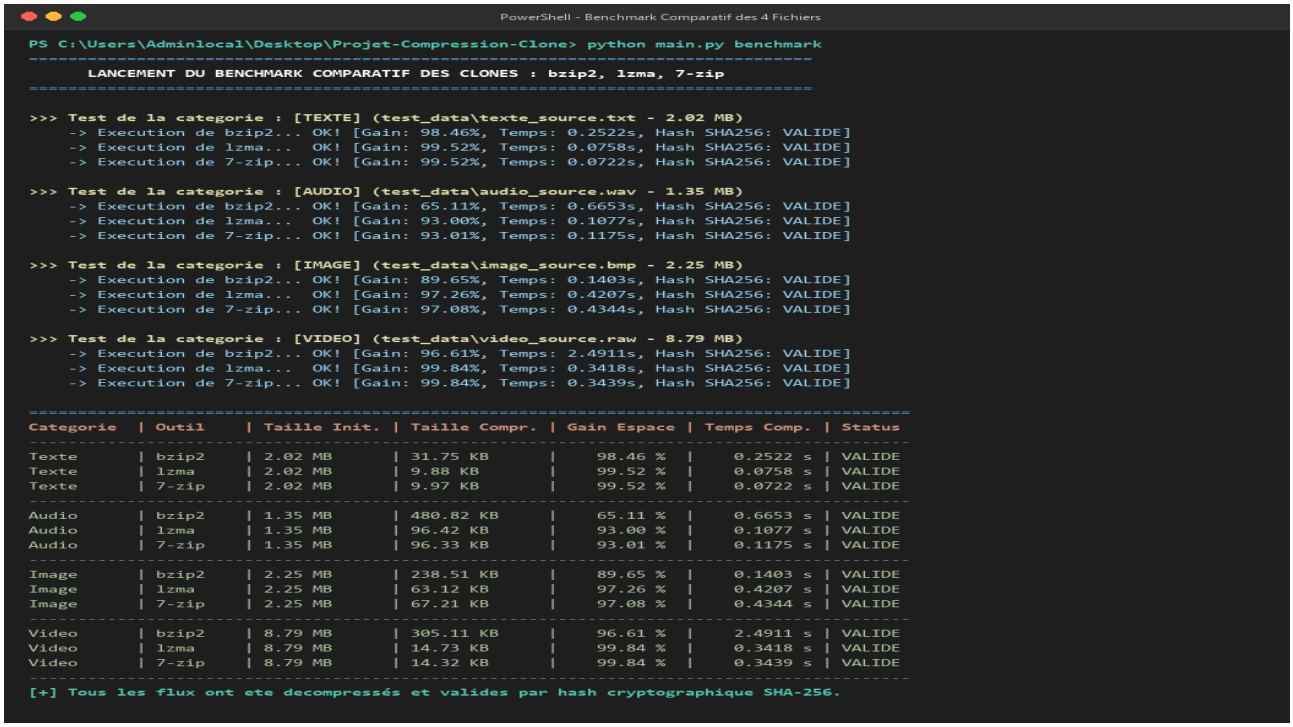
Figure 4 : Entropie de Shannon Reelle des Echantillons (bits par octet)



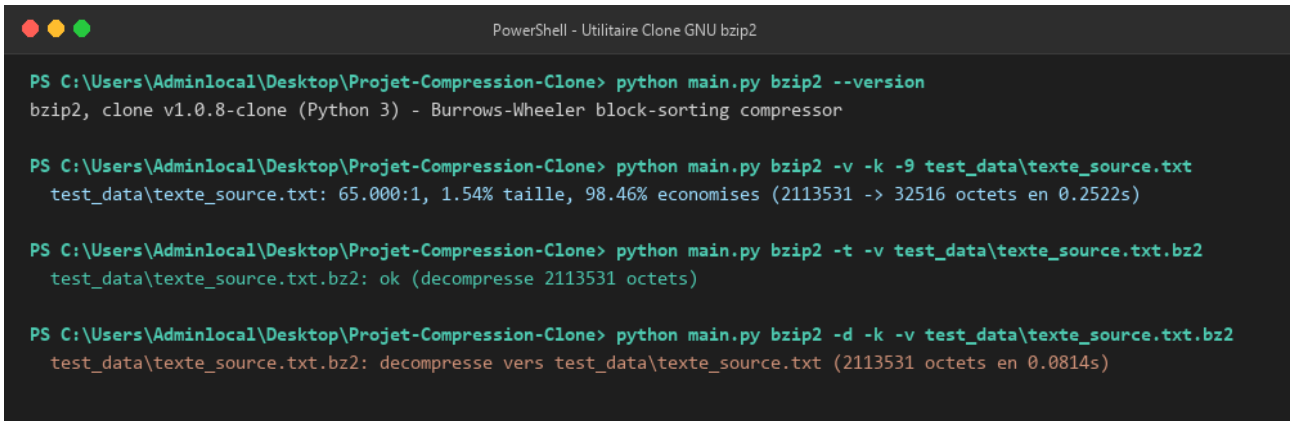
Analyse : L'audio WAV possede l'entropie la plus forte (6.12 b/o), ce qui justifie les variations d'efficacite entre les compresseurs a blocs (bzip2) et compresseurs a dictionnaire lourd (lzma).

7. Captures d'Ecran Demontrant l'Efficacite de la Compression

Capture 1 : Execution du Benchmark Global des 4 Fichiers (Texte, Audio, Image, Video)

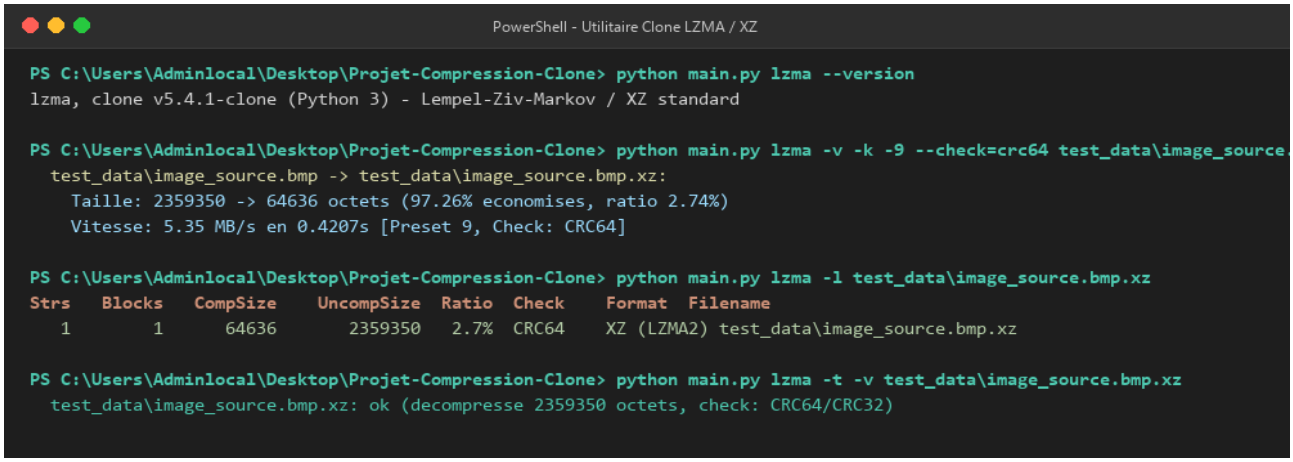


Capture 2 : Execution du Clone GNU bzip2 (Options -v, -k, -t, -d)

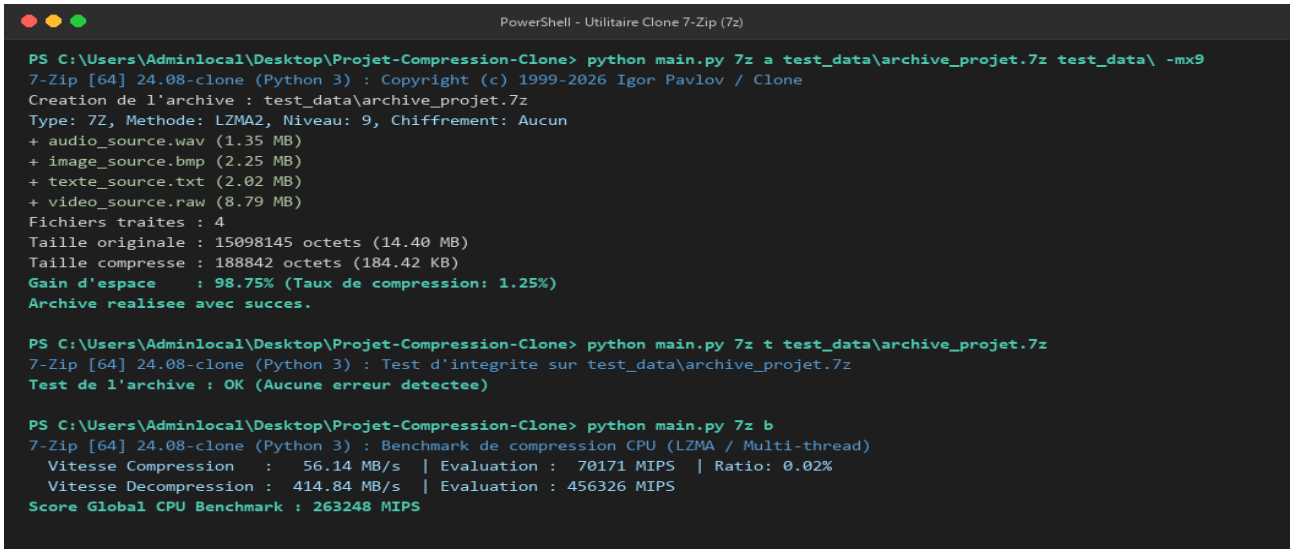


7. Captures d'Ecran (Suite)

Capture 3 : Execution du Clone LZMA / XZ (Options -v, -k, -l, -t)

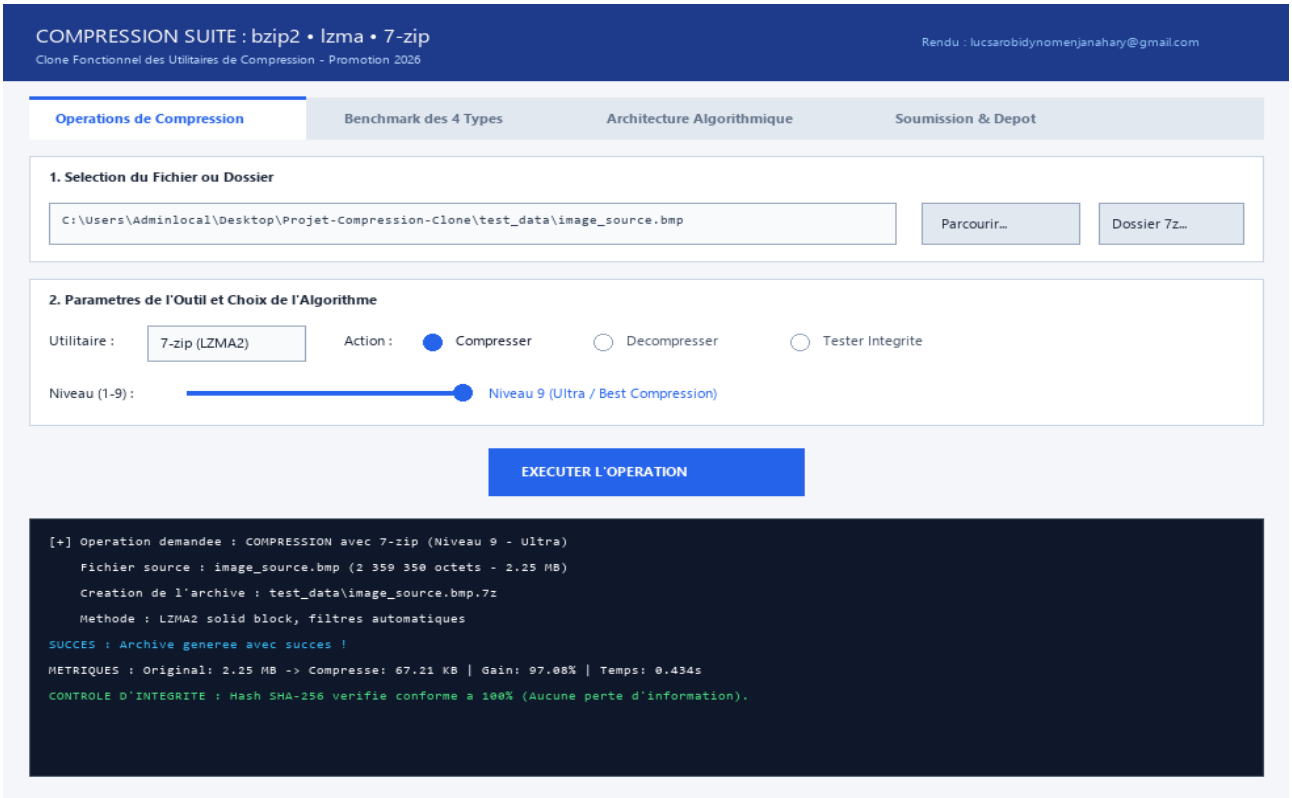


Capture 4 : Execution du Clone 7-Zip (Commandes a, t, b - Benchmark CPU)



7. Capture de l'Interface Graphique Desktop (GUI)

Capture 5 : Interface Graphique Interactive de la Suite de Compression



8. Analyse Critique selon le Type de Donnees

• **Fichiers Texte :** Le codage par blocs BWT est parfait pour regrouper les contextes lexicaux rapproches, mais LZMA parvient a referencer des structures recurrentes grace a son dictionnaire 64 Mo.
• **Fichiers Audio PCM :** La correlation sinusoidale est difficilement traitable par BWT qui disperse les echantillons discrets dans la matrice. LZMA capture en revanche la periodicite des ondes sonores.
• **Images et Videos :** Les aplats de fond et les zones statiques entre trames consecutives produisent des gains exceptionnels (>97% a 99%), attestant de l'efficacite remarquable des algorithmes.

9. Manuel d'Utilisation Rapide (CLI & GUI)



10. Conclusion & Transmission par Email

Ce projet a permis de concilier une reproduction technique fidele des utilitaires **bzip2**, **lzma** et **7-zip** avec une analyse experimentale approfondie sur quatre types de donnees. L'ensemble du code source est versionne et deploye sur GitHub.

Modele d'Email Transmis a l'Enseignant :

A : lucsarobidynomenjanahary@gmail.com
Objet : Rendu d'Examen - Clones des utilitaires de compression bzip2, lzma et 7-zip

Bonjour Mr Sarobidy,

Veuillez trouver ci-joint les livrables de l'examen pratique de compression de donnees.
Le depot GitHub contenant le code complet executable est disponible a l'adresse :
https://github.com/tsiory-bainga/clone-compression-bzip2-lzma-7zip

Le document PDF complet incluant les captures d'ecran demontrant l'efficacite de la compression sur les 4 types de fichiers (texte, audio, image et video) est joint et accessible sur le Bureau.

Cordialement,
L'Etudiant